

TRABAJO FIN DE MÁSTER

CASO DE NEGOCIO

MODELO PREDICTIVO DE LA LONGITUD TOTAL DEL INTESTINO DELGADO PARA APLICAR EN CIRUGÍA BARIÁTRICA BASADO EN ANÁLISIS DE DATOS Y TÉCNICAS DE INTELIGENCIA ARTIFICIAL

Máster in Data Science & Artificial Intelligence (MIDS & AI) 2023

CESTE Escuela Internacional de Negocios

Alumno

JOSÉ FERNANDO TREBOLLE

Tutores

JESÚS LOBO POYO

CARMEN PELLICER LOSTAO



TRABAJO FIN DE MÁSTER

INTRODUCCIÓN Y ESTADO ACTUAL DEL TEMA

MODELO PREDICTIVO DEL OBJETIVO TOTAL DEL
JUSTIFICACIÓN Y OBJETIVOS

INTESTINO DELGADO PARA APLICAR EN CIRUGÍA
CASOS DE USO

BARIÁTRICA BASADO EN ANÁLISIS DE DATOS Y TÉCNICAS

KPI (KEY PERFORMANCE INDICATORS)

Máster in Data Science & Artificial Intelligence (MIDS & AI) 2023

MATERIAL Y MÉTODO

CESTE Escuela Internacional de Negocios

Alumno

JOSÉ FERNANDO TREBOLLE

RESULTADOS

Tutores

JESÚS LOBO POYO

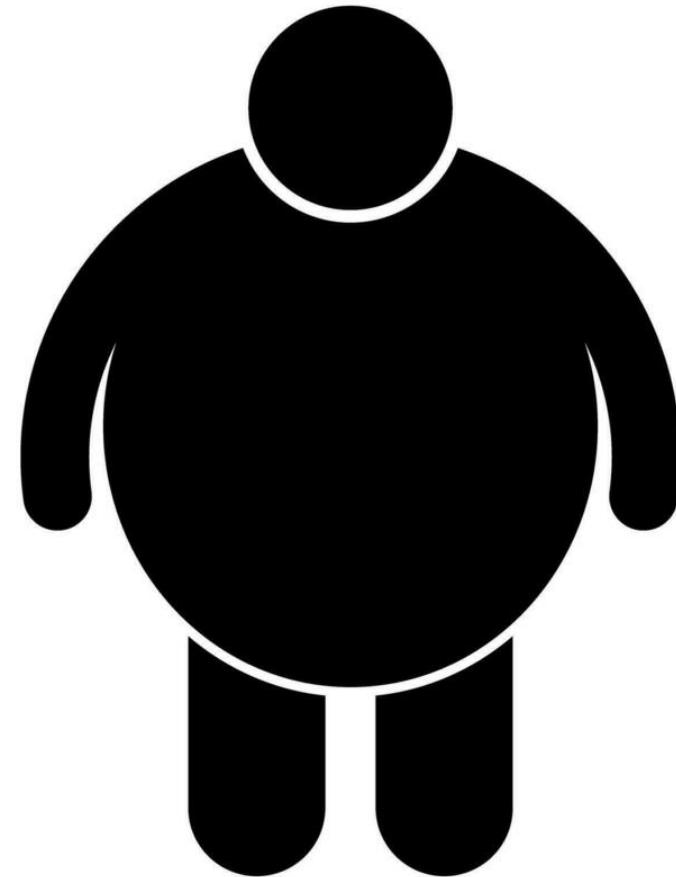
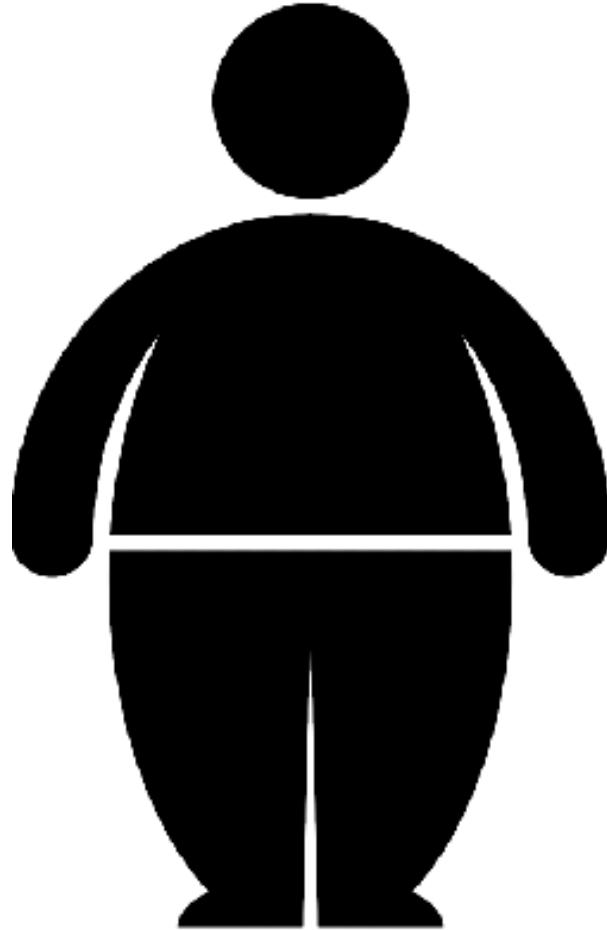
CARMEN PELLICER LOSTAO

LÍNEAS FUTURAS

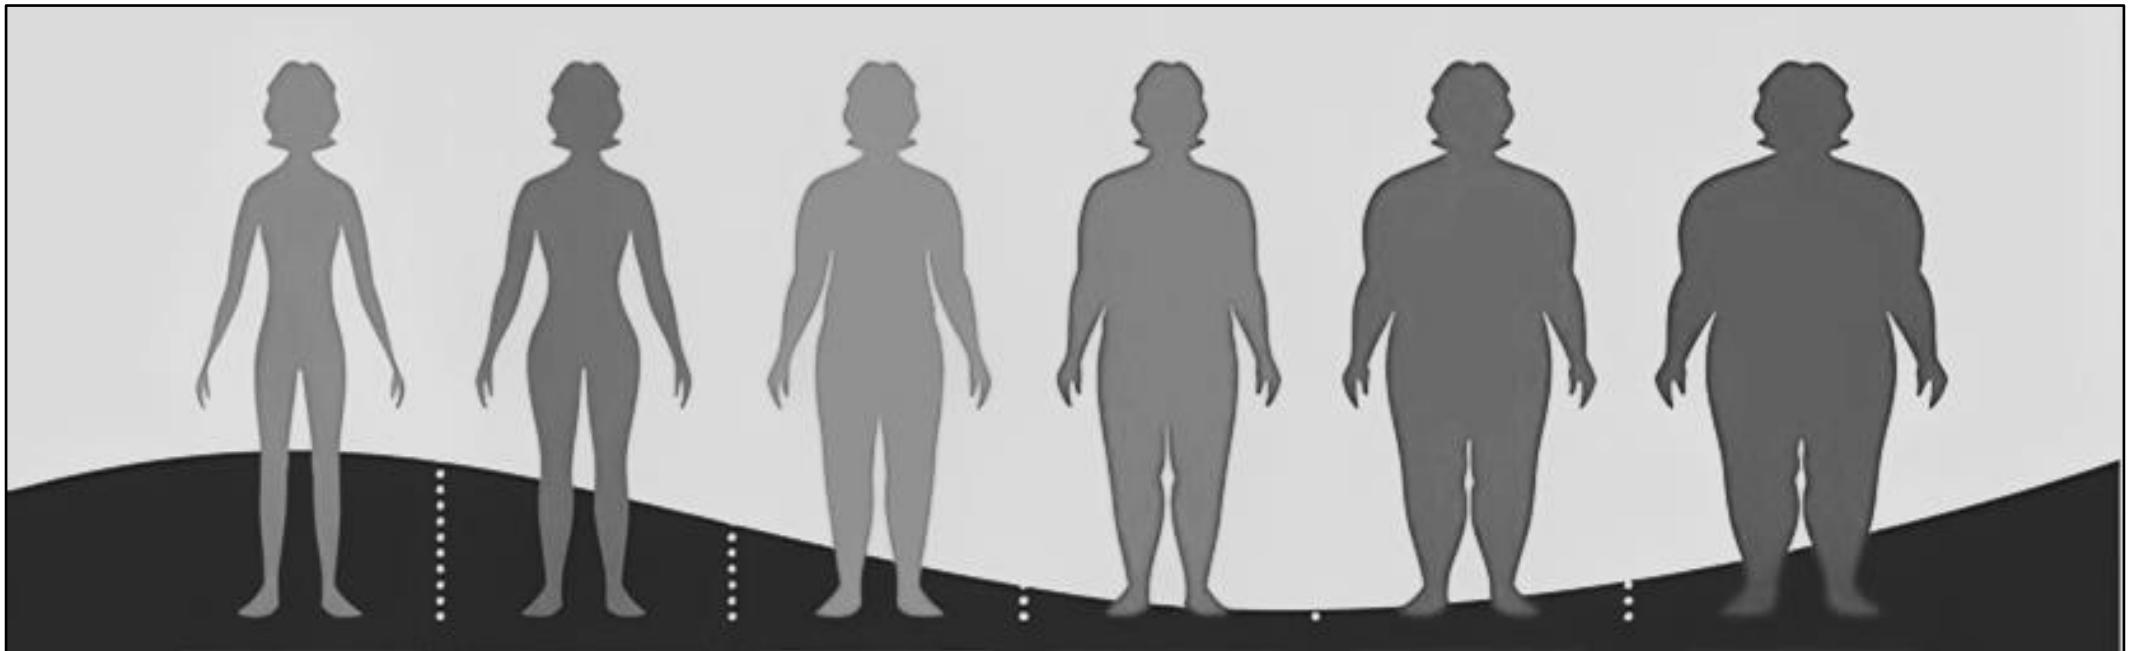
CONCLUSIONES



INTRODUCCIÓN Y ESTADO ACTUAL DEL TEMA



INTRODUCCIÓN Y ESTADO ACTUAL DEL TEMA



< 18.5

18.5 – 24.9

25 – 29.9

30 – 34.9

35 – 39.9

> 40

SOBREPESO

OBESIDAD I

OBESIDAD II

OBESIDAD III

IMC

INTRODUCCIÓN Y ESTADO ACTUAL DEL TEMA

TRATAMIENTO MULTIDISCIPLINAR

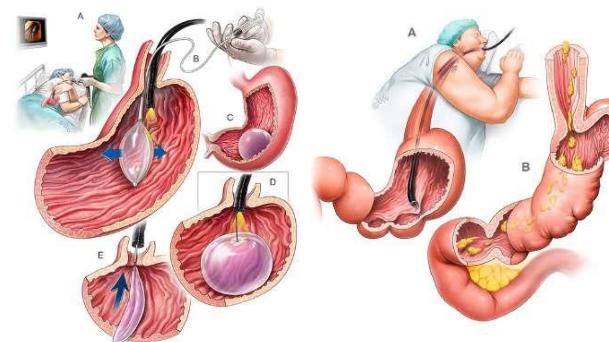
RÉGIMEN DE VIDA / TRATAMIENTO MÉDICO / TÉCNICAS ENDOSCÓPICAS / TRATAMIENTO QUIRÚRGICO



- Fármacos análogos de GLP-1
 - * Exenatida
 - * Liraglutida
 - * Dulaglutida
 - * Semaglutida

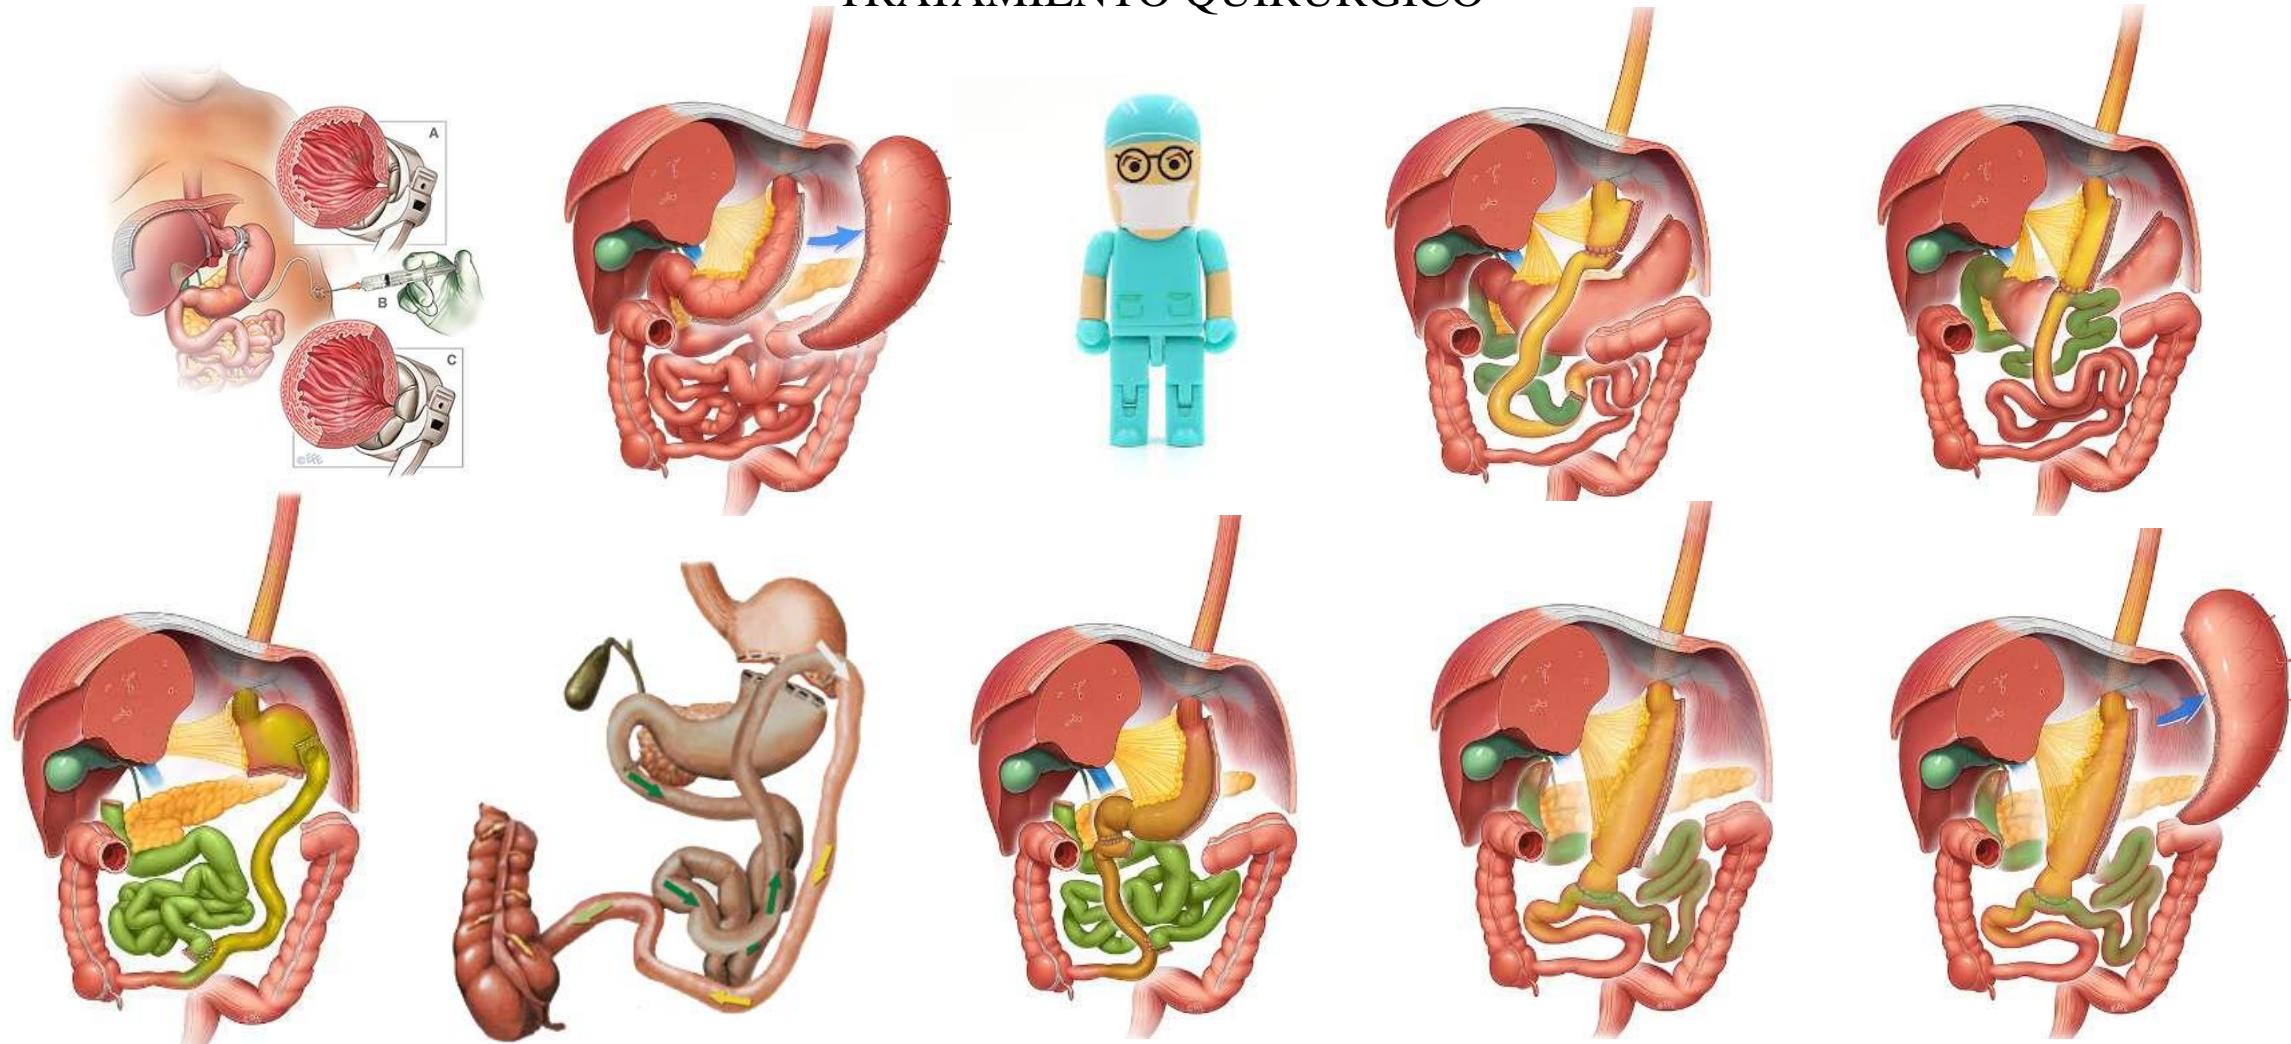


- Orlistat
- Naltrexona + Bupropion



INTRODUCCIÓN Y ESTADO ACTUAL DEL TEMA

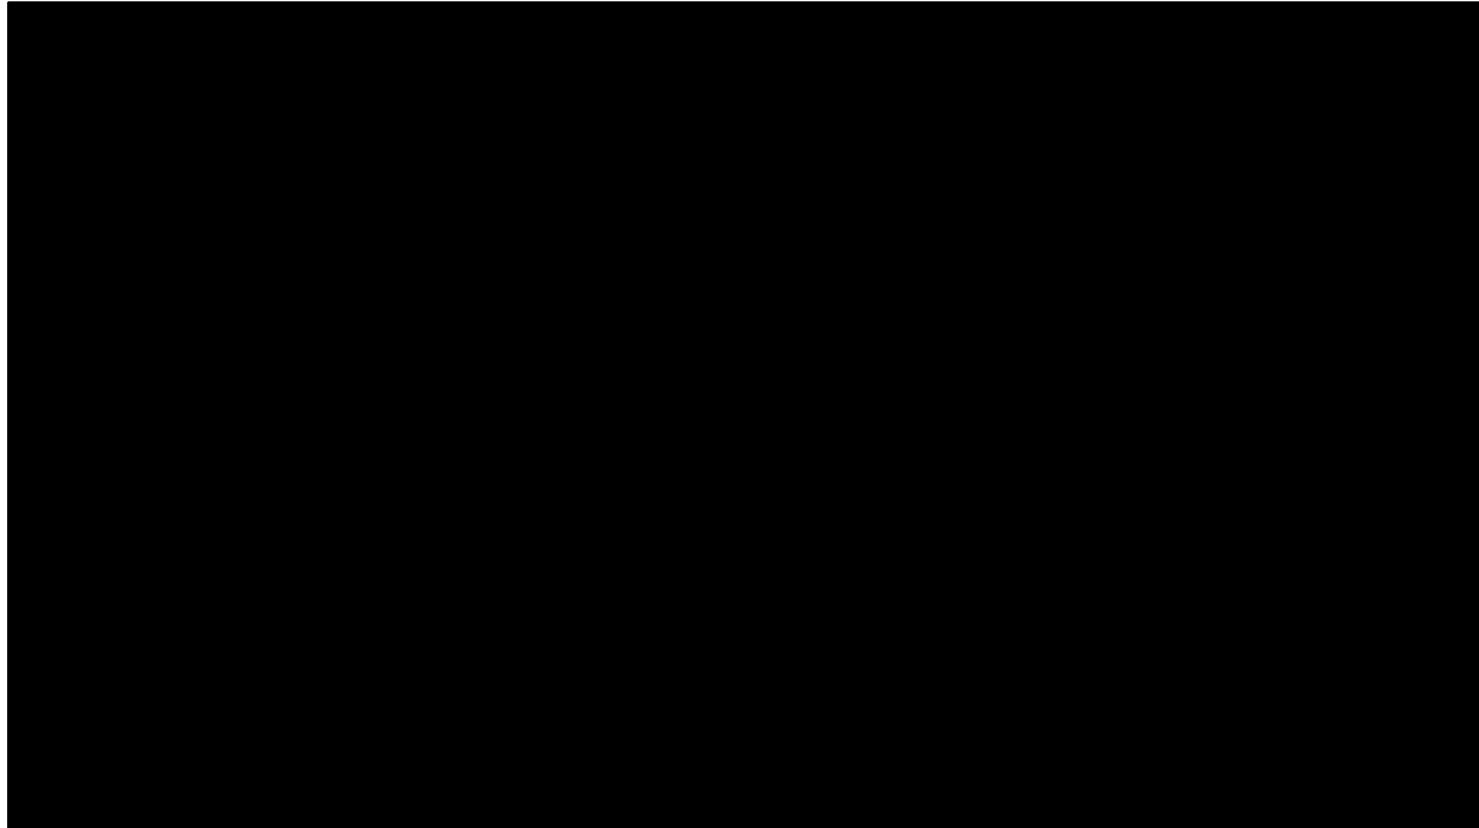
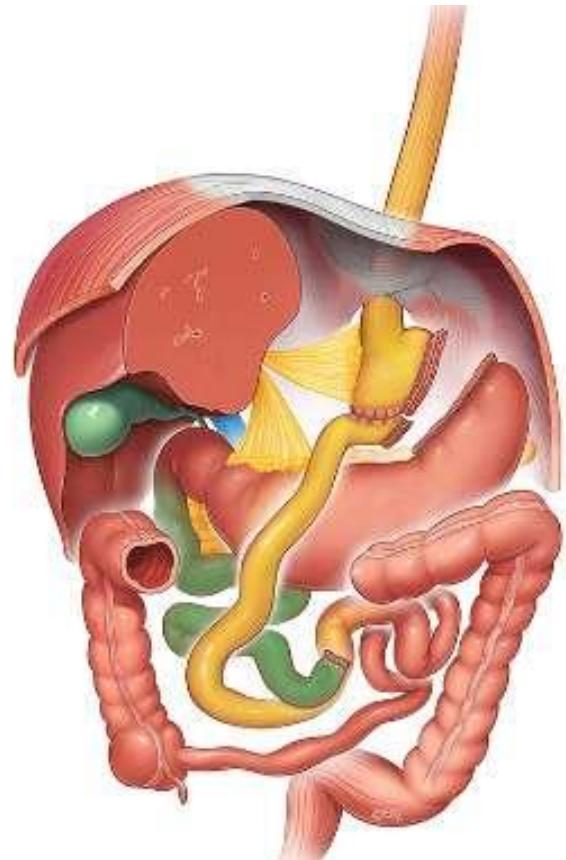
TRATAMIENTO QUIRÚRGICO



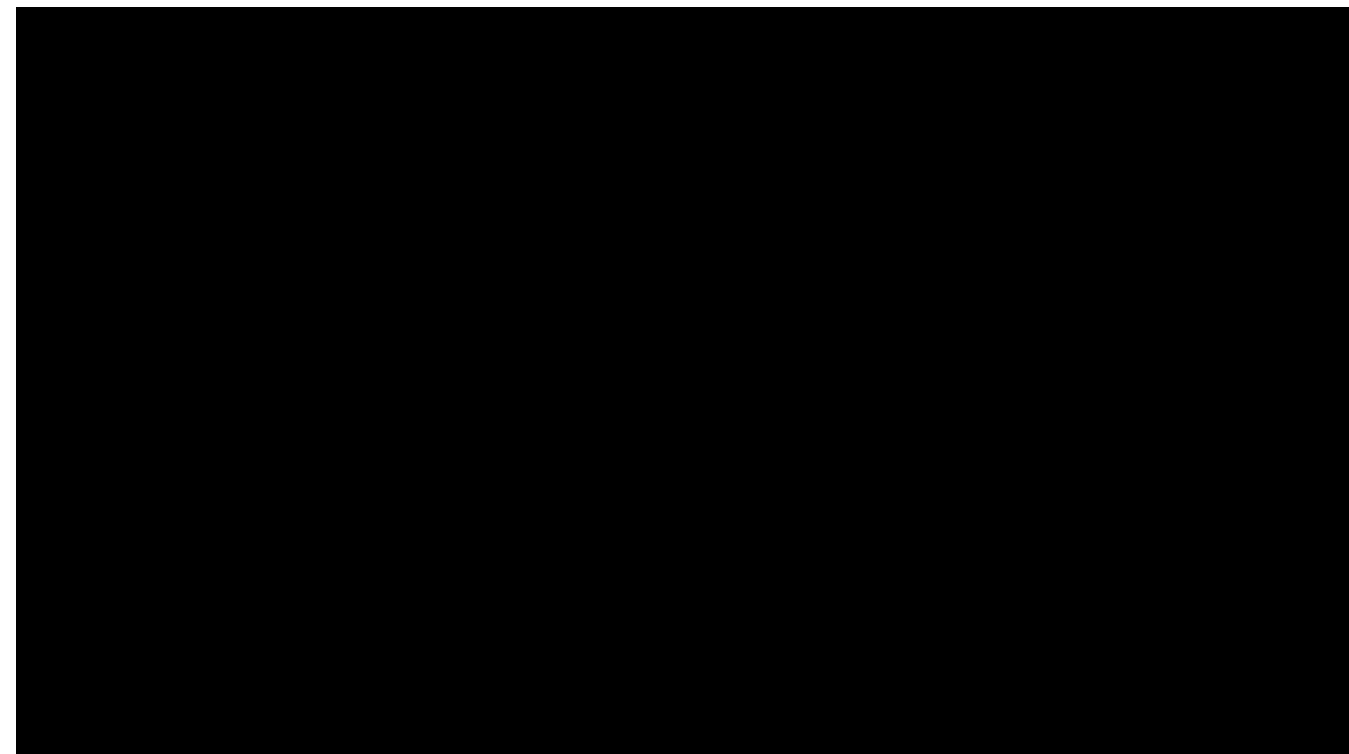
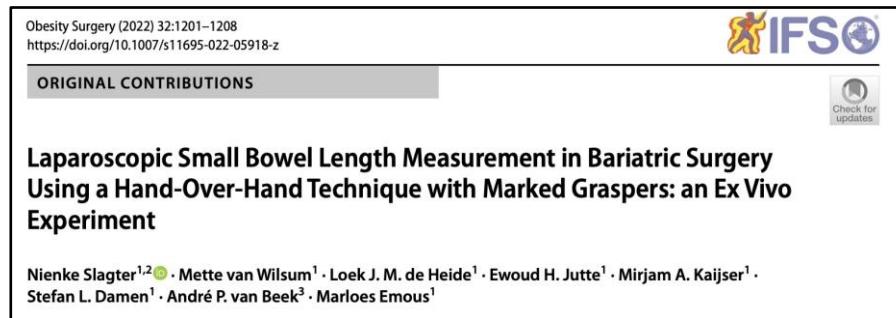
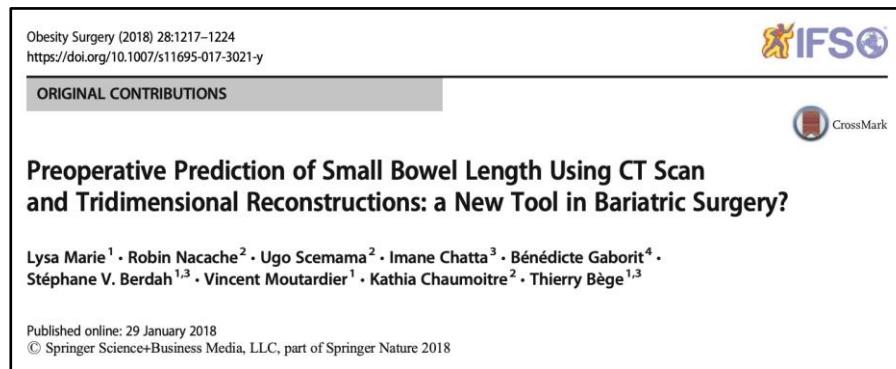
INTRODUCCIÓN Y ESTADO ACTUAL DEL TEMA

TRATAMIENTO QUIRÚRGICO

BY-PASS GÁSTRICO LAPAROSCÓPICO



INTRODUCCIÓN Y ESTADO ACTUAL DEL TEMA



INTRODUCCIÓN Y ESTADO ACTUAL DEL TEMA

World Journal of Gastroenterology

Submit a Manuscript: <https://www.f6publishing.com>

DOI: 10.3748/wjg.v27.i21.2758

World J Gastroenterol 2021 June 7; 27(21): 2758-2770

ISSN 1007-9327 (print) ISSN 2219-2840 (online)

MINIREVIEWS

Artificial intelligence in perioperative management of major gastrointestinal surgeries

Sohan Lal Solanki, Saneya Pandrowala, Abhirup Nayak, Manish Bhandare, Reshma P Ambulkar, Shailesh V Shrikhande

Surgery Today (2022) 52:995–1007
<https://doi.org/10.1007/s00595-021-02380-9>

REVIEW ARTICLE



Machine learning in gastrointestinal surgery

Takashi Sakamoto^{1,2}  · Tadahiro Goto^{2,3} · Michimasa Fujiogi^{4,5} · Alan Kawarai Lefor⁶

Received: 1 May 2021 / Accepted: 3 July 2021 / Published online: 24 September 2021
© Springer Nature Singapore Pte Ltd. 2021

Obesity Surgery (2022) 32:2772–2783
<https://doi.org/10.1007/s11695-022-06146-1>

IFSO



REVIEW

Artificial Intelligence in Bariatric Surgery: Current Status and Future Perspectives

Mustafa Bektaş¹ · Beata M. M. Reiber¹ · Jaime Costa Pereira² · George L. Burchell³ · Donald L. van der Peet¹

Received: 24 February 2022 / Revised: 3 June 2022 / Accepted: 3 June 2022 / Published online: 17 June 2022
© The Author(s) 2022

Obesity Surgery (2022) 32:2717–2733
<https://doi.org/10.1007/s11695-022-06100-1>

IFSO



REVIEW

Current Applications of Artificial Intelligence in Bariatric Surgery

Valentina Bellini¹ · Marina Valente² · Melania Turetti¹ · Paolo Del Rio² · Francesco Saturno¹ · Massimo Maffezzoni¹ · Elena Bignami¹ 

Received: 21 November 2021 / Revised: 2 May 2022 / Accepted: 4 May 2022 / Published online: 26 May 2022
© The Author(s) 2022

CellPress

Cell
Leading Edge

Review

From patterns to patients: Advances in clinical machine learning for cancer diagnosis, prognosis, and treatment

Kyle Swanson,^{1,6} Eric Wu,^{2,6} Angela Zhang,^{3,6} Ash A. Alizadeh,⁴ and James Zou^{1,2,5,*}

¹Department of Computer Science, Stanford University, Stanford, CA, USA
²Department of Electrical Engineering, Stanford University, Stanford, CA, USA
³Department of Genetics, Stanford University, Stanford, CA, USA
⁴Department of Medicine, Stanford University, Stanford, CA, USA
⁵Department of Biomedical Data Science, Stanford University, Stanford, CA, USA
⁶These authors contributed equally
^{*}Correspondence: jamesz@stanford.edu
<https://doi.org/10.1016/j.cell.2023.01.035>

JUSTIFICACIÓN Y OBJETIVOS

CIENCIA DE DATOS → INTELIGENCIA ARTIFICIAL → ALGORITMO DE PREDICCIÓN

Objetivos técnicos

- Individualizar la cirugía bariátrica a cada modelo de paciente.
- Disminuir el tiempo operatorio.
- Disminuir el riesgo de aparición de complicaciones intraoperatorias derivadas de un gesto de importante complejidad técnica.
- Obtener un mejor resultado postoperatorio de pérdida ponderal y de efecto metabólico.
- Reducir los efectos adversos producidos por las complicaciones derivadas de una cirugía bariátrica no individualizada.

OBJETIVOS

Objetivos económicos

- Optimizar el coste del proceso disminuyendo la utilización del tiempo de quirófano, y mejorando el gasto de material.
- Disminuir el gasto de medicación necesaria para paliar los síntomas derivados de una cirugía bariátrica no individualizada por malabsorción o desnutrición.
- Disminuir el coste derivado de cirugías revisionales por aparición de complicaciones de la cirugía primaria que precisan de una segunda cirugía para ser tratadas.

Objetivos de calidad

- Mejorar la calidad asistencial por parte del equipo quirúrgico.
- Mejorar la satisfacción del paciente por tener una cirugía bariátrica individualizada a su caso, con una garantía de éxito mayor que si no se realizara de este modo.

CASOS DE USO

CASO 1: Analizar la serie de población bariátrica de la Unidad de Cirugía Laparoscópica Avanzada del Hospital Quironsalud de Zaragoza conociendo sus variables físicas y demográficas, así como la técnica realizada, el tiempo operatorio y la estancia postoperatoria, y así hacer una auditoría de resultados técnicos según la cirugía realizada.

CASO 2: Realizar un análisis poblacional de los pacientes intervenidos por la Unidad de Cirugía Laparoscópica Avanzada del Hospital Quironsalud de Zaragoza que permita establecer una estrategia de captación y seguimiento de pacientes abriendo sedes de consulta más próximas a las comunidades autónomas con mayor número de pacientes operados.

CASO 3: Estudiar la posible relación entre el lugar de origen de los pacientes de la Unidad de Cirugía Laparoscópica Avanzada del Hospital Quironsalud de Zaragoza y la morfología de su intestino delgado en cuanto a longitud, que permita hacer un estudio anatómico-poblacional de interés científico.

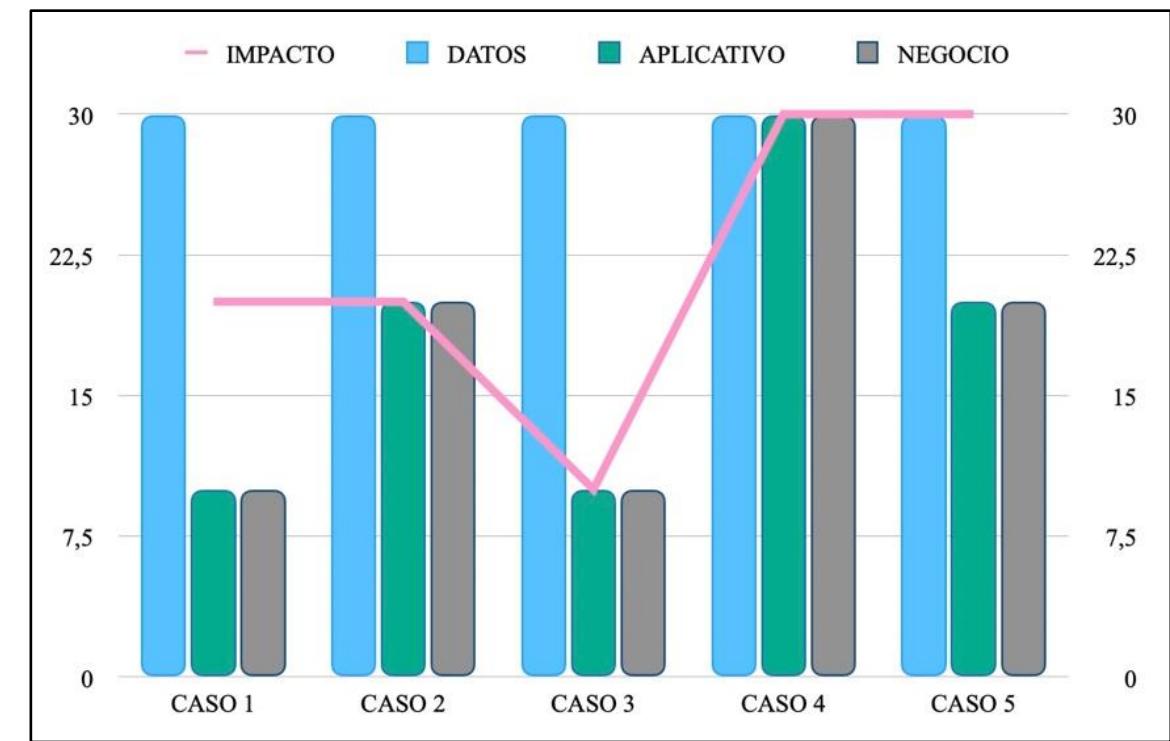
CASO 4: Desarrollar un modelo predictivo de la longitud total del intestino delgado para aplicar en cirugía bariátrica en técnicas derivativas que permita individualizar la cirugía según las características de cada paciente.

CASO 5: Valorar el impacto en resultados de pérdida ponderal y de resolución de comorbilidades tras la cirugía bariátrica o metabólica realizada por la Unidad de Cirugía Laparoscópica Avanzada del Hospital Quironsalud de Zaragoza.

CASOS DE USO

MATRIZ Y GRÁFICA DE DECISIÓN CASOS DE USO

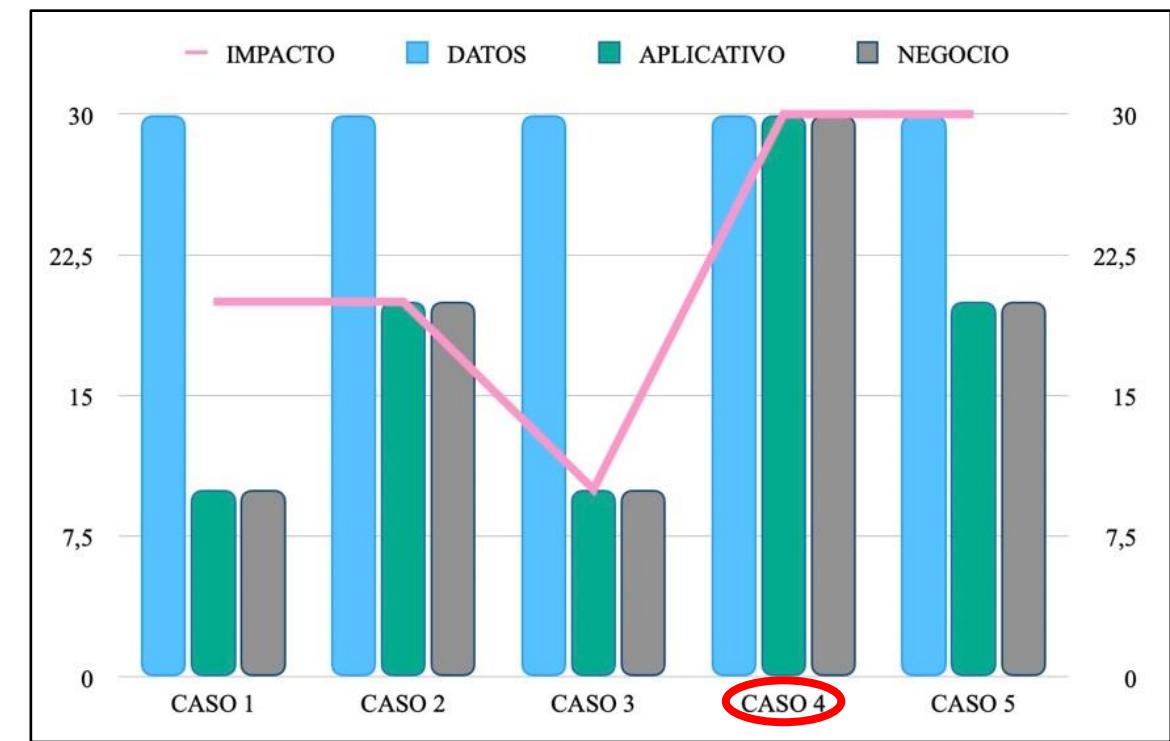
	IMPACTO	DATOS	APLICATIVO	NEGOCIO
CASO 1	20/30	30/30	10/30	10/30
CASO 2	20/30	30/30	20/30	20/30
CASO 3	10/30	30/30	10/30	10/30
CASO 4	30/30	30/30	30/30	30/30
CASO 5	30/30	30/30	20/30	20/30



CASOS DE USO

MATRIZ Y GRÁFICA DE DECISIÓN CASOS DE USO

	IMPACTO	DATOS	APLICATIVO	NEGOCIO
CASO 1	20/30	30/30	10/30	10/30
CASO 2	20/30	30/30	20/30	20/30
CASO 3	10/30	30/30	10/30	10/30
CASO 4	30/30	30/30	30/30	30/30
CASO 5	30/30	30/30	20/30	20/30



CASOS DE USO

CASO 1: Analizar la serie de población bariátrica de la Unidad de Cirugía Laparoscópica Avanzada del Hospital Quironsalud de Zaragoza conociendo sus variables físicas y demográficas, así como la técnica realizada, el tiempo operatorio y la estancia postoperatoria, y así hacer una auditoría de resultados técnicos según la cirugía realizada.

CASO 2: Realizar un análisis poblacional de los pacientes intervenidos por la Unidad de Cirugía Laparoscópica Avanzada del Hospital Quironsalud de Zaragoza que permita establecer una estrategia de captación y seguimiento de pacientes abriendo sedes de consulta más próximas a las comunidades autónomas con mayor número de pacientes operados.

CASO 3: Estudiar la posible relación entre el lugar de origen de los pacientes de la Unidad de Cirugía Laparoscópica Avanzada del Hospital Quironsalud de Zaragoza y la morfología de su intestino delgado en cuanto a longitud, que permita hacer un estudio anatómico-poblacional de interés científico.

CASO 4: Desarrollar un modelo predictivo de la longitud total del intestino delgado para aplicar en cirugía bariátrica en técnicas derivativas que permita individualizar la cirugía según las características de cada paciente.

Cirugía bariátrica primaria / Cirugía bariátrica de revisión

CASO 5: Valorar el impacto en resultados de pérdida ponderal y de resolución de comorbilidades tras la cirugía bariátrica o metabólica realizada por la Unidad de Cirugía Laparoscópica Avanzada del Hospital Quironsalud de Zaragoza.

KPI (KEY PERFORMANCE INDICATORS)

KPI 1: Porcentaje de cirugías individualizadas midiendo toda la longitud del intestino.

- a. Fórmula: Número de cirugías bariátricas individualizadas / Número total de cirugías bariátricas x 100.
- b. Actual: 73 %.
- c. Target mínimo: 90 %.
- d. Target objetivo: 100 %.

$$\frac{\text{Número de cirugías bariátricas individualizadas}}{\text{Número total de cirugías bariátricas}} \times 100$$

KPI 2: Porcentaje de acierto de la longitud del intestino delgado utilizando el algoritmo predictivo.

- a. Fórmula: (1 – Longitud total con medida manual – Longitud total con algoritmo predictivo / Longitud total con medida manual) x 100.
- b. Actual: 0 % (no se emplea).
- c. Target mínimo: +/- 10 % de la longitud total con medida manual.
- d. Target objetivo: +/- 5 % de la longitud total con medida manual.

$$(1 - \frac{\text{Longitud total con medida manual} - \text{Longitud total con algoritmo predictivo}}{\text{Longitud total con medida manual}}) \times 100$$

KPI 3: Porcentaje de disminución del tiempo operatorio (desde la entrada hasta la salida del quirófano) utilizando el algoritmo predictivo.

- a. Fórmula: (1 – Tiempo operatorio con medida manual – Tiempo operatorio con algoritmo predictivo / Tiempo operatorio con medida manual) x 100.
- b. Actual: 0 % (no se emplea).
- c. Target mínimo: 10 % del tiempo operatorio actual (84 minutos).
- d. Target objetivo: 16 % del tiempo operatorio actual (84 minutos).

$$(1 - \frac{\text{Tiempo operatorio con medida manual} - \text{Tiempo operatorio con algoritmo predictivo}}{\text{Tiempo operatorio con medida manual}}) \times 100$$

KPI (KEY PERFORMANCE INDICATORS)

KPI 4: Porcentaje de ahorro de tiempo en cada turno para aumentar el número de cirugías que pueden añadirse en el parte quirúrgico.

- a. Fórmula: $(1 - \frac{\text{Tiempo operatorio total con medida manual} - \text{Tiempo operatorio total con algoritmo predictivo}}{\text{Tiempo operatorio medio con medida manual}}) \times 100$
- b. Actual: 0 % (no se emplea).
- c. Target mínimo: 10 % del tiempo operatorio actual (84 minutos).
- d. Target objetivo: 16 % del tiempo operatorio actual (84 minutos).

KPI 5: Porcentaje de reducción de complicaciones intraoperatorias producidas durante las maniobras de medida con el uso del algoritmo predictivo.

- a. Fórmula: $(1 - \frac{\text{Complicaciones producidas con medida manual} - \text{Complicaciones producidas con algoritmo predictivo}}{\text{Complicaciones producidas con medida manual}}) \times 100$
- b. Actual: 0 % (no se emplea).
- c. Target mínimo: 1 % (el porcentaje actual de complicaciones es del 2 %).
- d. Target objetivo: 2 % (el porcentaje actual de complicaciones es del 2 %).

KPI (KEY PERFORMANCE INDICATORS)

KPI 6: Porcentaje de mejora en el resultado de pérdida ponderal en cirugía bariátrica utilizando el algoritmo predictivo.

- a. Fórmula: Pérdida ponderal con algoritmo predictivo – Pérdida ponderal sin algoritmo predictivo / Pérdida ponderal esperada x 100.

$$\frac{\text{Pérdida ponderal con algoritmo predictivo} - \text{Pérdida ponderal sin algoritmo predictivo}}{\text{Pérdida ponderal esperada}} \times 100$$

KPI 7: Porcentaje de mejora en resultado de resolución de comorbilidades en cirugía metabólica utilizando el algoritmo predictivo.

- a. Fórmula: Tasa de resolución de comorbilidades con algoritmo predictivo – Tasa de resolución de comorbilidades sin algoritmo predictivo / Tasa de resolución de comorbilidades esperada x 100.

$$\frac{\text{Tasa de resolución de comorbilidades con algoritmo predictivo} - \text{Tasa de resolución de comorbilidades sin algoritmo predictivo}}{\text{Tasa de resolución de comorbilidades esperada}} \times 100$$

KPI 8: Porcentaje de cirugías revisionales evitadas tras individualizar la intervención quirúrgica utilizando el algoritmo predictivo.

- a. Fórmula: Número de cirugías revisionales con algoritmo predictivo / Número total de cirugías revisionales x 100.

$$\frac{\text{Número de cirugías revisionales con algoritmo predictivo}}{\text{Número total de cirugías revisionales}} \times 100$$

KPI (KEY PERFORMANCE INDICATORS)

KPI 9: Porcentaje de mejora en el tiempo de recuperación realizando una cirugía individualizada conociendo la longitud completa del intestino delgado.

- a. Fórmula: Duración media de la recuperación en cirugías no individualizadas – Duración media de la recuperación en cirugías individualizadas / Duración media de la recuperación en cirugías no individualizadas x 100.

$$\frac{\text{Duración media de la recuperación en cirugías no individualizadas} - \text{Duración media de la recuperación en cirugías individualizadas}}{\text{Duración media de la recuperación en cirugías no individualizadas}} \times 100$$

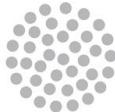
KPI 10: Porcentaje de pacientes satisfechos (mejora del índice de satisfacción del cliente) con el resultado de su intervención quirúrgica realizada de forma individualizada como signo de calidad asistencial.

- a. Fórmula: Índice de satisfacción antes de implementar la cirugía individualizada – Índice de satisfacción después de implementarla / Índice de satisfacción original x 100.

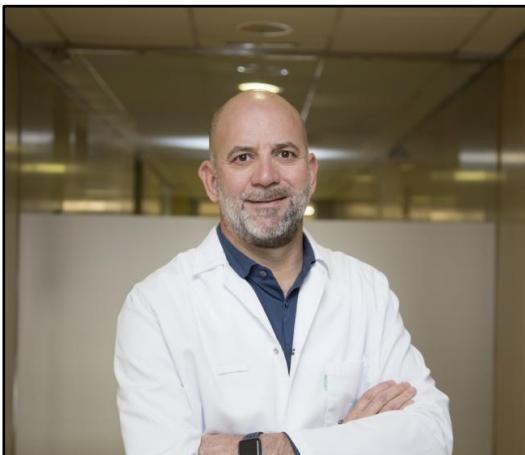
$$\frac{\text{Índice de satisfacción antes de implementar la cirugía individualizada} - \text{índice de satisfacción despues de implementarla}}{\text{índice de satisfacción original}} \times 100$$

MATERIAL Y MÉTODO

MATERIAL



indra



- Variables demográficas
- Antecedentes personales
- Cirugía

MATERIAL Y MÉTODO

MATERIAL Y MÉTODO

INICIALES	SEXO	EDAD	PESO	TALLA	IMC	CIUDAD	MUNICIPIO	CÓDIGO POSTAL	HTA	DM	DI	SAOS	BARIÁTRICA PREVIA	FECHA INGRESO	FECHA PARTE	HORA INICIO	TÉCNICA	TÉCNICA 2	HORA FINAL	MINUTOS	FECHA ALTA	ESTANCIA	COMPLICACIONES	LONGITUD TOTAL	ASA BILIOPANCREÁTICA	ASA ALIMENTARIA	ASA COMÚN
EMR	2	37	97	1,72	32,7879935	BARCELONA	VILADECANS	8840	NO	SI	NO	NO	ENDOBARRIER	12/5/15	12/5/15	15:55:00	BPPm	NO	17:20:00	85	15/5/15	3	NO	590	240	100	250
JMBA	1	69	122	1,81	37,2394005	MALAGA	BENALMÁDENA	29630	NO	SI	NO	NO	NO	19/5/15	19/5/15	18:00:01	BPPm	NO	19:36:32	96	22/5/15	3	NO	860	430	100	330
EZS	1	55	96	1,7	33,2179931	SORIA	ÁGREDA	42108	NO	SI	NO	NO	NO	1/6/15	1/6/15	15:57:18	BPPm	NO	17:19:45	82	3/6/15	2	NO	840	335	100	405
AML	2	60	112	1,65	41,1386593	ZARAGOZA	ZARAGOZA	50003	SI	SI	SI	NO	NO	8/6/15	8/6/15	15:45:34	BPPm	NO	17:25:34	100	10/6/15	2	NO	480	150	150	180
IMG	2	53	82	1,54	34,5758138	HUESCA	LAS PIÉAS DE RIGLOS	22830	NO	NO	NO	NO	NO	15/6/15	15/6/15	16:15:49	BPGm	NO	17:23:14	68	17/6/15	2	NO	460	120	100	240
MCG	2	53	76	1,6	29,6875	VALLADOLID	LAGUNA DE DUERO	47140	SI	SI	SI	NO	NO	16/6/15	16/6/15	17:45:00	BPPm	NO	18:51:39	66	18/6/15	2	NO	500	200	100	200
GRS	1	62	91	1,69	31,8616295	MALAGA	MIJAS	29651	SI	SI	SI	NO	NO	16/6/15	16/6/15	16:00:00	BPPm	NO	17:25:28	85	19/6/15	3	NO	730	290	100	340
FLMG	1	70	100	1,73	33,4124094	ZARAGOZA	RICLA	50270	SI	SI	SI	NO	NO	22/6/15	22/6/15	16:00:00	BPPm	NO	17:15:00	75	24/6/15	2	NO	730	290	100	340
EDCDLH	2	39	83	1,59	32,8309798	SANTA CRUZ DE TENERIFE	SAN MIGUEL DE ABONA	38628	NO	SI	SI	SI	NO	23/6/15	23/6/15	16:00:00	BPPm	NO	17:15:00	75	25/6/15	2	NO	600	240	100	260
MZI	1	57	128	1,75	41,7959184	GIPUZKOA	ASTEASU	20159	SI	SI	NO	NO	NO	23/6/15	23/6/15	17:25:00	BPPm	NO	18:34:50	69	25/6/15	2	NO	600	300	150	150
NOR	2	39	115	1,69	40,2646956	ZARAGOZA	ZARAGOZA	50012	NO	SI	NO	NO	NO	29/6/15	29/6/15	15:50:24	BPG	NO	18:35:24	165	1/7/15	2	NO	540	100	150	290
EAM	1	61	102	1,78	32,1929049	MADRID	ARGANDA DEL REY	28500	SI	SI	NO	NO	NO	30/6/15	30/6/15	17:35:24	BPPm	NO	18:50:26	75	3/7/15	3	NO	700	280	100	320
MOLC	2	53	94	1,56	38,625904	ZARAGOZA	LA ALMUNIA DE DOÑA GODINA	50100	NO	NO	NO	NO	NO	30/6/15	30/6/15	15:45:25	BPG	NO	17:20:37	95	2/7/15	2	NO	500	100	150	250
ACL	2	19	128	1,65	47,0155107	ZARAGOZA	MOVERA	50194	NO	NO	SI	NO	NO	6/7/15	6/7/15	15:49:42	BPG	NO	17:21:52	92	8/7/15	2	NO	500	100	200	200
PDCH	1	40	124	1,69	43,4158468	ZARAGOZA	ZARAGOZA	50001	NO	NO	NO	NO	NO	6/7/15	6/7/15	17:28:50	BPG	NO	19:06:54	98	8/7/15	2	NO	550	150	150	250
JMBC	1	49	130	1,74	42,93803	ALICANTE	ALMORADÍ	3160	SI	NO	NO	NO	NO	7/7/15	7/7/15	16:00:47	BPP	NO	17:50:14	110	9/7/15	2	NO	660	360	150	150
JICMP	1	46	127	1,79	39,6367155	TERUEL	ALCAÑÍZ	44600	NO	SI	NO	NO	NO	13/7/15	13/7/15	18:15:40	BPPm	NO	20:10:41	115	15/7/15	2	NO	650	350	150	150
BIS	1	54	134	1,72	31,970795	CASTELLÓN	NULES	12520	SI	NO	NO	NO	NO	14/7/15	14/7/15	15:50:22	BPP	NO	17:15:22	85	17/7/15	3	NO	675	375	150	150
PMDP	1	56	90	1,74	29,7265161	LAS PALMAS	GÁLDAR	35460	SI	SI	NO	NO	NO	14/7/15	14/7/15	17:35:22	BPPm	NO	19:00:24	85	18/7/15	4	HIPOTENSIÓN	670	270	100	300
AGM	1	66	74	1,52	32,0290859	HUELVA	HUELVA	21005	SI	SI	SI	NO	NO	21/7/15	21/7/15	17:25:00	BPPm	NO	18:50:00	85	24/7/15	3	NO	700	280	100	320
VMS	2	22	102	1,62	38,8660265	ZARAGOZA	ZARAGOZA	50001	NO	NO	NO	NO	NO	7/9/15	7/9/15	17:45:00	BPG	NO	19:15:00	90	9/9/15	2	NO	400	100	150	150
LANB	1	73	95	1,58	38,0547989	ZARAGOZA	RICLA	50270	SI	SI	NO	NO	NO	7/9/15	7/9/15	16:00:00	BPPm	NO	17:30:00	90	11/9/15	4	SHOCK ANAFILÁCTICO	625	240	100	285
HO	1	72	93	1,7	32,1799308	BARCELONA	SANT BOI DE LLOBREGAT	8830	SI	SI	SI	NO	NO	8/9/15	8/9/15	17:50:00	BPPm	NO	20:30:00	160	11/9/15	3	NO	560	225	100	235
ISM	1	55	131	1,65	48,117539	GIPUZKOA	ASTEASU	20159	NO	NO	NO	NO	NO	8/9/15	8/9/15	16:00:00	BPP	NO	17:34:00	94	11/9/15	3	NO	700	350	175	175
PFV	1	68	88	1,72	29,7458085	ZARAGOZA	ZARAGOZA	50015	SI	SI	SI	NO	NO	14/9/15	14/9/15	15:40:00	BPPm	NO	17:45:00	65	16/9/15	2	NO	540	220	100	220
LACY	1	52	89	1,6	34,765625	LEIIDA	MOLLERUSA	25230	NO	SI	NO	NO	NO	15/9/15	15/9/15	15:50:00	BPPm	NO	17:30:00	100	18/9/15	3	NO	610	240	100	270
ELM	1	33	148	1,71	50,6138641	SORIA	SORIA	42001	SI	NO	SI	NO	NO	15/9/15	15/9/15	17:40:00	BPP	NO	19:15:00	95	18/9/15	3	NO	700	350	175	175
MCAR	2	41	148	1,64	55,0267698	ZARAGOZA	ANÍJON	50313	NO	NO	NO	NO	NO	21/9/15	21/9/15	17:23:00	BPP	NO	18:42:00	79	23/9/15	2	NO	560	280	140	140
IRC	2	52	74	1,54	31,2025637	NAVARRA	ETXAURI	31174	SI	SI	NO	NO	NO	21/9/15	21/9/15	15:44:00	BPPm	NO	17:18:00	94	23/9/15	2	NO	670	260	100	310
ECM	1	69	99	1,61	34,6626519	MURCIA	ARCHENA	30600	SI	SI	SI	NO	NO	22/9/15	22/9/15	16:02:00	BPPm	NO	17:15:00	73	25/9/15	3	NO	820	340	100	380
AVM	2	59	72	1,56	29,5857898	MADRID	MADRID	28012	NO	SI	NO	NO	NO	22/9/15	22/9/15	17:21:00	BPPm	NO	18:59:00	98	25/9/15	3	NO	480	190	100	190
RDCDH	1	65	125	1,69	43,7659746	LA RIOJA	LOGROÑO	26001	SI	SI	SI	NO	ENDOMANGA	28/9/15	28/9/15	18:10:00	BPP	NO	19:30:00	80	30/9/15	2	NO	770	385	170	215
MAAY	2	69	87	1,59	34,4131957	MADRID	MADRID	28033	SI	SI	SI	NO	NO	29/9/15	29/9/15	17:30:00	BPPm	NO	18:30:00	60	2/10/15	3	NO	570	230	100	240
MGR	1	68	110	1,68	36,973929	MÁLAGA	MÁLAGA	29010	SI	SI	SI	NO	NO	29/9/15	29/9/15	15:45:00	BPPm	NO	17:30:00	105	2/10/15	3	NO	710	350	175	185
BGL	2	53	106	1,61	41,6650592	SORIA	SORIA	42003	NO	NO	NO	NO	NO	6/10/15	6/10/15	17:45:00	BPG	NO	18:40:00	55	8/10/15	2	NO	640	200	100	340
CRM	1	55	115	1,64	33,6739713	MADRID	LAS ROZAS DE MADRID	28232	SI	SI	SI	NO	NO	6/10/15	6/10/15	16:00:00	BPPm	NO	17:15:00	75	9/10/15	3	NO	850	340	100	410
VPC	1	59	111	1,76	35,8343942	ZARAGOZA	CASETAS	50620	SI	SI	SI	NO	NO	13/10/15	13/10/15	15:45:00	BPPm	NO	17:00:00	75	15/10/15	2	NO	650	260	100	290
ELC	2	30	133	1,57	53,9575642	TARRAGONA	REUS	43202	NO	NO	NO	NO	NO	19/10/15	19/10/15	15:30:00	BPG	NO	17:45:00	135	21/10/15	2	NO	530	100	200	230
AMMM	2	37	133	1,63	50,0583387	ZARAGOZA	ZARAGOZA	50010	NO	NO	NO	NO	NO	19/10/15	19/10/15	17:30:00	BPG	NO	19:00:00	90	21/10/15	2	NO	490	100	145	245
FIGL	1	18	146	1,68	51,7290249	ALICANTE	DOLORES	3150	NO	NO	NO	NO	NO	20/10/15	20/10/15	16:10:00	BPP	NO	17:30:00	80	22/10/15	2	NO	730	365	180	185
CLG	1	38	154	1,66	44,5138166	ZARAGOZA	ZARAGOZA	50014	NO	NO	NO	NO	NO	26/10/15	26/10/15	17:14:00	BPG	NO	19:56:00	162	28/10/15	2	NO	560	100	180	280
CAMT	1	69	106	1,7	36,6782007	HUESCA	HUESCA	22005	SI	NO	NO	NO	NO	26/10/15	26/10/15	15:49:00	BPPm	NO	17:07:00	78	28/10/15	2	NO	640	320	160	320
MPZ	1	47	115	1,76	37,1735165	ZARAGOZA	ZARAGOZA	50007	SI	NO	SI	NO	NO	27/10/15	27/10/15	17:17:00	BPG	NO	18:42:00	85	29/10/15	2	NO	735	100	250	385
MIRD	2	48	85	1,65	31,2213039	MÁLAGA	HUESCA	29603	NO	SI	NO	NO	NO	27/10/15	27/10/15												

MATERIAL Y MÉTODO

MÉTODO



SEXO / EDAD / IMC / LONGITUD TOTAL

SEXO / EDAD / PESO / TALLA / IMC / LONGITUD TOTAL

- Análisis descriptivo de la serie (test t de Student).
- Análisis de correlación de variables (test de correlación de Pearson / test ANOVA).
- Análisis de regresión lineal.
- Transformación y escalado de datos (MinMax Scaler).
- Clustering (machine learning).
- Interpolación de datos (machine learning sobremuestreo modo SMOTE).
- Modelización (XGBoost).



RESULTADOS

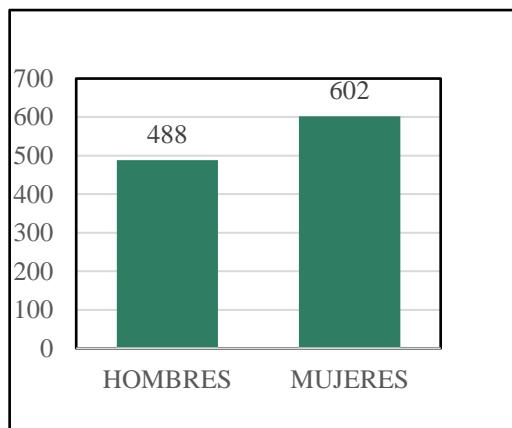
n = 1090 casos

mayo 2015 – junio 2023

SEXO / EDAD / PESO / TALLA / IMC / LONGITUD TOTAL

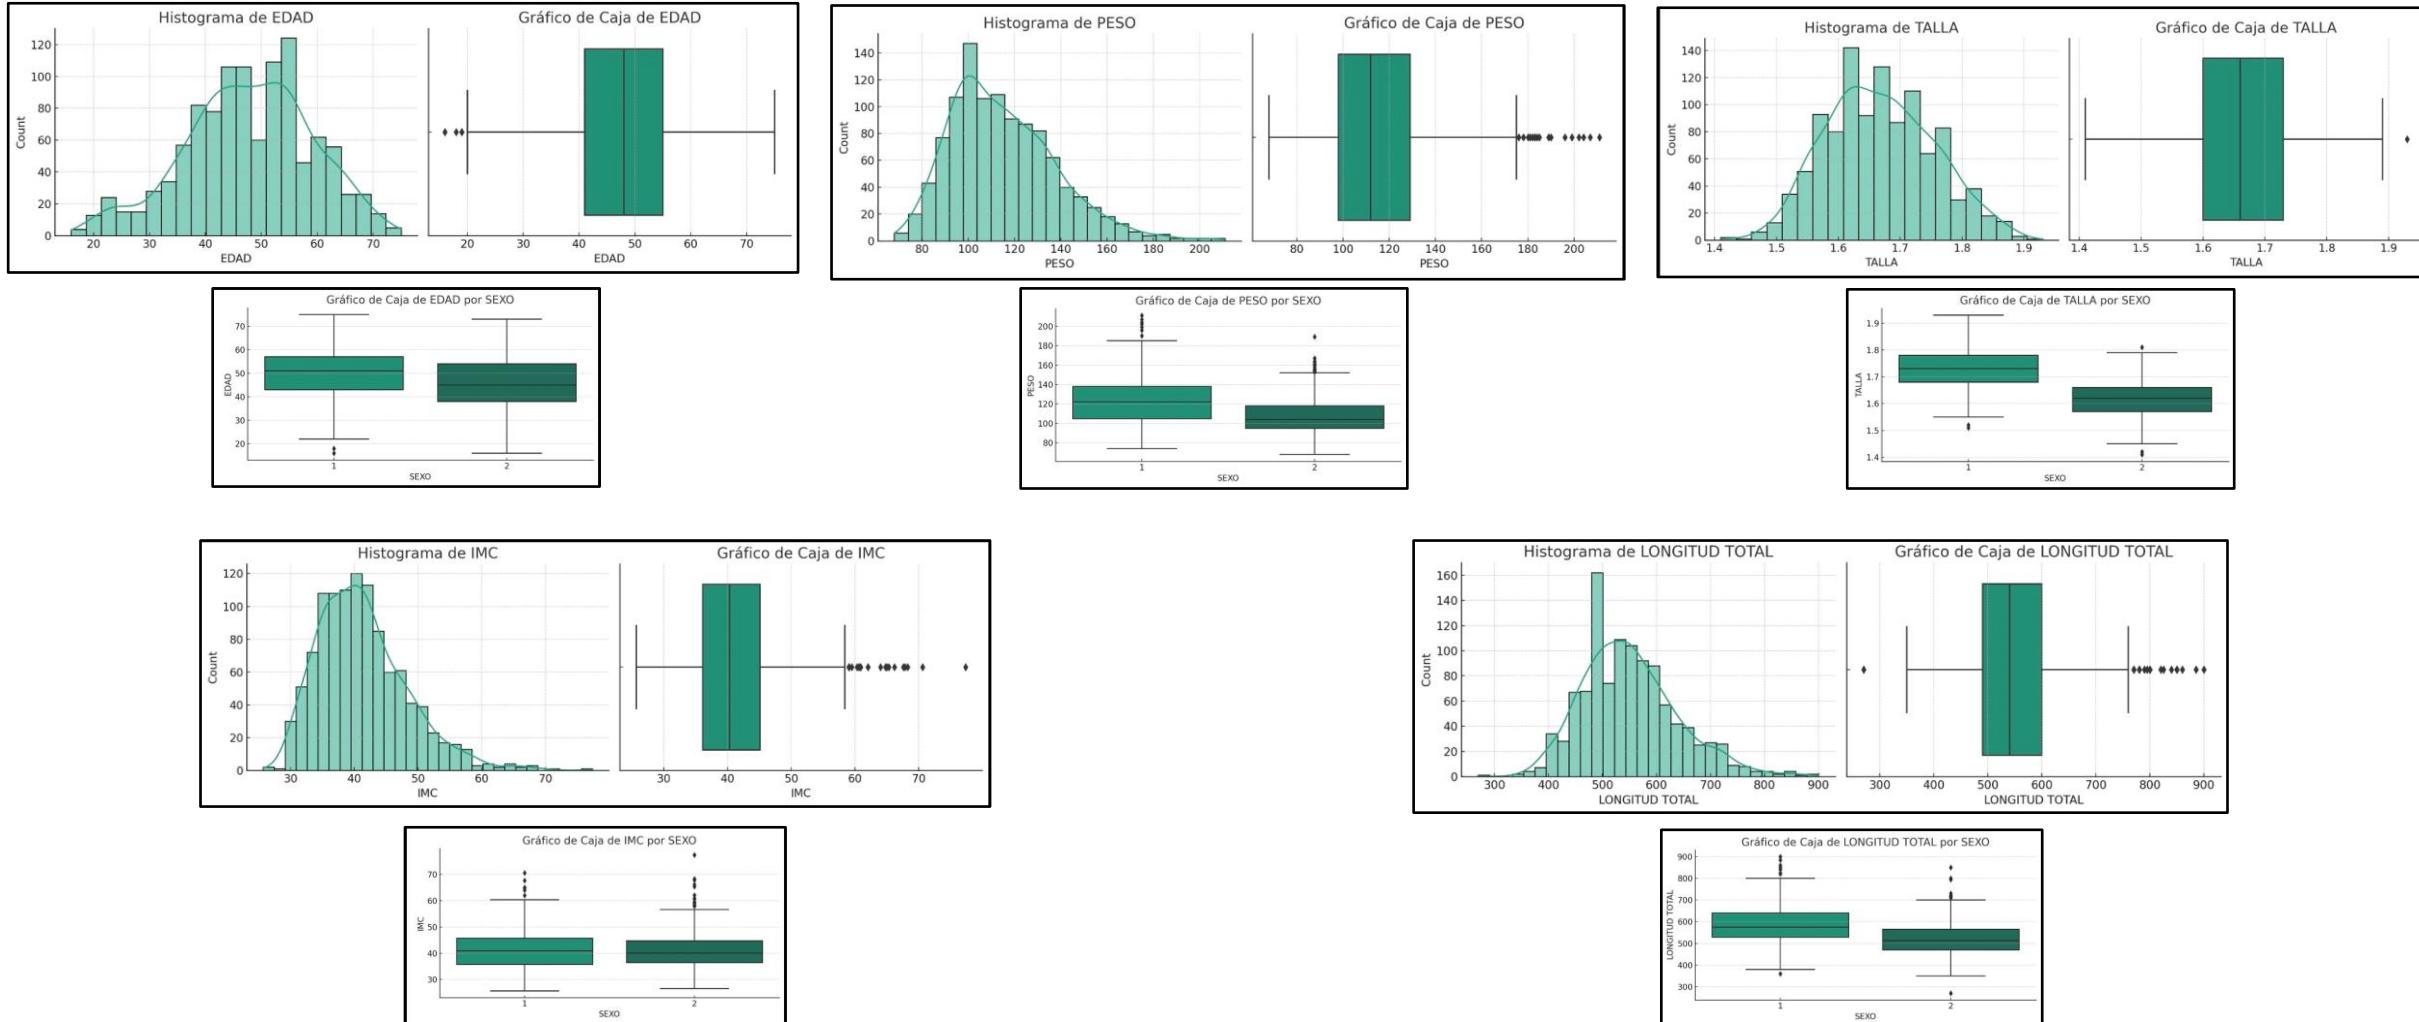
Análisis descriptivo

- Variable SEXO:
 - Hombres (1) – 488 (44.03 %).
 - Mujeres (2) – 602 (55.22 %).
- Variable EDAD: Media – 47.7 años [16 – 75].
 - Hombres (1) – 50.61 años [16 – 75].
 - Mujeres (2) – 45.34 años [16 – 73].
 - Test t de Student: $p = 6.50e-15$.
- Variable PESO: Media – 115.03 kg [68 – 211].
 - Hombres (1) – 123.93 kg [74 – 211].
 - Mujeres (2) – 107.80 kg [68 – 189].
 - Test t de Student: $p = 1.20e-30$.
- Variable TALLA: Media – 1.67 m [1.41 – 1.93].
 - Hombres (1) – 1.73 m [1.51 – 1.93].
 - Mujeres (2) – 1.61 m [1.41 – 1.81].
 - Test t de Student: $p = 1.11e-124$.
- Variable IMC: Media – 41.26 [25.69 – 77.37].
 - Hombres (1) – 41.34 [25.69 – 70.59].
 - Mujeres (2) – 41.15 [26.57 – 77.37].
 - Test t de Student: $p = 0.76$.
- Variable LONGITUD TOTAL: Media – 550.58 cm [270 – 900].
 - Hombres (1) – 587.34 cm [360 – 900].
 - Mujeres (2) – 520.78 cm [270 – 850].
 - Test t de Student: $p = 8.38e-36$.



RESULTADOS

Análisis descriptivo



RESULTADOS

Análisis de correlación de variables

- SEXO y LONGITUD TOTAL:
 - o Test de correlación de Pearson: coeficiente = - 0.374 ($p = 1.54e-37$).
 - o Test ANOVA: F-valor 177.05 ($p = 1.54e-37$).
- EDAD y LONGITUD TOTAL:
 - o Test de correlación de Pearson: coeficiente = 0.194 ($p = 9.79e-11$).
- PESO y LONGITUD TOTAL:
 - o Test de correlación de Pearson: coeficiente = 0.089 ($p = 0.003$).
- TALLA y LONGITUD TOTAL:
 - o Test de correlación de Pearson: coeficiente = 0.321 ($p = 1.25e-27$).
- IMC y LONGITUD TOTAL:
 - o Test de correlación de Pearson: coeficiente = - 0.093 ($p = 0.002$).

SEXO	1	- 0.23	- 0.35	- 0.65	- 0.0094	- 0.37
EDAD	- 0.23	1	- 0.21	- 0.08	- 0.19	0.19
PESO	- 0.35	- 0.21	1	0.52	0.84	- 0.089
TALLA	- 0.65	- 0.08	0.52	1	- 0.0094	0.32
IMC	- 0.0094	- 0.19	0.84	- 0.0094	1	- 0.093
LONGITUD TOTAL	- 0.37	0.19	0.089	0.32	- 0.093	1
	SEXO	EDAD	PESO	TALLA	IMC	LONGITUD TOTAL

RESULTADOS

Análisis de regresión lineal

- SEXO y LONGITUD TOTAL: Coeficiente R²: 0.140.
- EDAD y LONGITUD TOTAL: Coeficiente R²: 0.0378.
- PESO y LONGITUD TOTAL: Coeficiente R²: 0.0080.
- TALLA y LONGITUD TOTAL: Coeficiente R²: 0.1034.
- IMC y LONGITUD TOTAL: Coeficiente R²: 0.0087.

Modelo de regresión múltiple

- LONGITUD TOTAL = 13.29 + 1.68 * EDAD + 0.23 * PESO + 292.65 * TALLA - 1.41 * IMC + 0.00 * SEXO.
 - o Coeficientes:
 - Intercepto: 13.29; SEXO: 0.00; EDAD: 1.68; PESO: 0.23; TALLA: 292.65; IMC: - 1.41.
 - o Evaluación:
 - Error cuadrático medio (MSE): 6649.61.
 - Coeficiente R²: 0.16.
- Hombres: LONGITUD TOTAL = 265.09 + 1.25 * EDAD + 0.42 * PESO + 166.39 * TALLA - 1.96 * IMC.
- Mujeres: LONGITUD TOTAL = - 305.01 + 1.03 * EDAD - 2.60 * PESO + 509.18 * TALLA + 5.73 * IMC.

RESULTADOS

Transformación de datos

MinMaxScaler: df 0 sin escalar, df 1 sin longitud (scaler 1), y df 2 con longitud (scaler 2).

	count	mean	std	min	25%	50%	75%	max
EDAD	1090.0	47.708257	11.380764	16.000000	41.000000	48.000000	55.000000	75.000000
PESO	1090.0	115.025688	23.018723	68.000000	98.000000	112.000000	129.000000	211.000000
TALLA	1090.0	166.743119	8.734849	141.000000	160.000000	166.000000	173.000000	193.000000
IMC	1090.0	41.264023	7.035458	25.689562	36.143848	40.346505	45.129549	77.365602
SEXO_1	1090.0	0.447706	0.497486	0.000000	0.000000	0.000000	1.000000	1.000000
SEXO_2	1090.0	0.552294	0.497486	0.000000	0.000000	1.000000	1.000000	1.000000
LONGITUD	1090.0	550.582569	88.519893	270.000000	490.000000	540.000000	600.000000	900.000000

df 0 sin escalar

	count	mean	std	min	25%	50%	75%	max
EDAD	1090.0	0.537428	0.192894	0.0	0.423729	0.542373	0.661017	1.0
PESO	1090.0	0.328851	0.160970	0.0	0.209790	0.307692	0.426573	1.0
TALLA	1090.0	0.495060	0.167978	0.0	0.365385	0.480769	0.615385	1.0
IMC	1090.0	0.301386	0.136145	0.0	0.202304	0.283631	0.376190	1.0
SEXO_1	1090.0	0.447706	0.497486	0.0	0.000000	0.000000	1.000000	1.0
SEXO_2	1090.0	0.552294	0.497486	0.0	0.000000	1.000000	1.000000	1.0
LONGITUD	1090.0	550.582569	88.519893	270.0	490.000000	540.000000	600.000000	900.0

df 1 sin longitud (scaler 1)

	count	mean	std	min	25%	50%	75%	max
EDAD	1090.0	0.537428	0.192894	0.0	0.423729	0.542373	0.661017	1.0
PESO	1090.0	0.328851	0.160970	0.0	0.209790	0.307692	0.426573	1.0
TALLA	1090.0	0.495060	0.167978	0.0	0.365385	0.480769	0.615385	1.0
IMC	1090.0	0.301386	0.136145	0.0	0.202304	0.283631	0.376190	1.0
SEXO_1	1090.0	0.447706	0.497486	0.0	0.000000	0.000000	1.000000	1.0
SEXO_2	1090.0	0.552294	0.497486	0.0	0.000000	1.000000	1.000000	1.0
LONGITUD	1090.0	0.445369	0.140508	0.0	0.349206	0.428571	0.523810	1.0

df 2 con longitud (scaler 2)

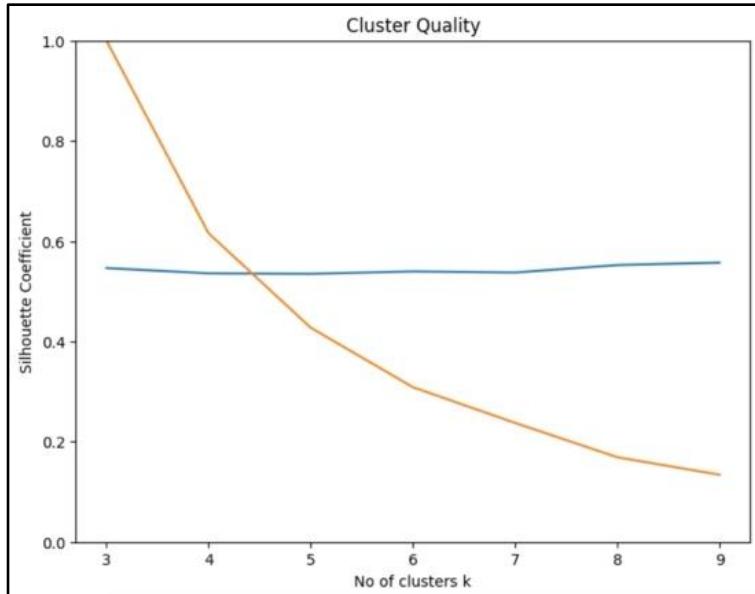
	count	mean	std	min	25%	50%	75%	max
EDAD	1090.0	0.537428	0.192894	0.0	0.423729	0.542373	0.661017	1.0
PESO	1090.0	0.328851	0.160970	0.0	0.209790	0.307692	0.426573	1.0
TALLA	1090.0	0.495060	0.167978	0.0	0.365385	0.480769	0.615385	1.0
IMC	1090.0	0.301386	0.136145	0.0	0.202304	0.283631	0.376190	1.0
SEXO_1	1090.0	0.447706	0.497486	0.0	0.000000	0.000000	1.000000	1.0
SEXO_2	1090.0	0.552294	0.497486	0.0	0.000000	1.000000	1.000000	1.0
LONGITUD	1090.0	550.582569	88.519893	270.0	490.000000	540.000000	600.000000	900.0

RESULTADOS

Clustering

Machine learning no supervisado

```
3 clusers - 0.063740 seconds - 0.546146 silhouette coef - 1615730.380023 cost
4 clusers - 0.093881 seconds - 0.535721 silhouette coef - 994634.050473 cost
5 clusers - 0.099411 seconds - 0.534792 silhouette coef - 690217.178600 cost
6 clusers - 0.102954 seconds - 0.539462 silhouette coef - 498493.763365 cost
7 clusers - 0.103674 seconds - 0.537321 silhouette coef - 383458.399380 cost
8 clusers - 0.050825 seconds - 0.552193 silhouette coef - 272694.022869 cost
9 clusers - 0.203885 seconds - 0.557012 silhouette coef - 216390.991873 cost
```



scaler 1

	EDAD	PESO	TALLA	IMC	SEXO_1	SEXO_2	LONGITUD
k3_c0	0.494308	0.314946	0.442451	0.314398	0.251244	0.748756	465.223881
k3_c1	0.548125	0.331002	0.502486	0.299122	0.486869	0.513131	564.585859
k3_c2	0.599807	0.352295	0.585592	0.280093	0.756477	0.243523	692.461140

original

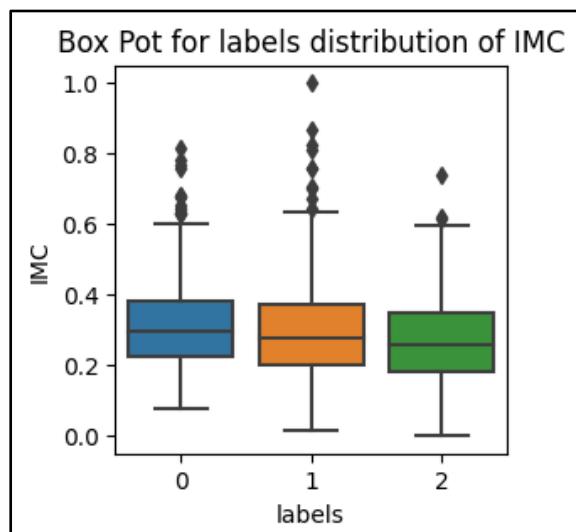
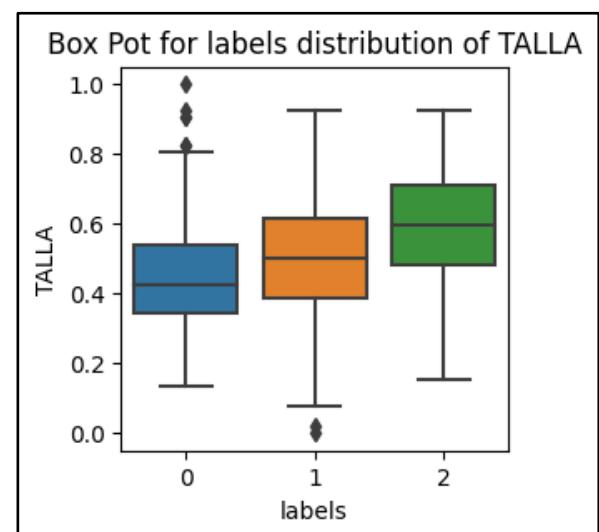
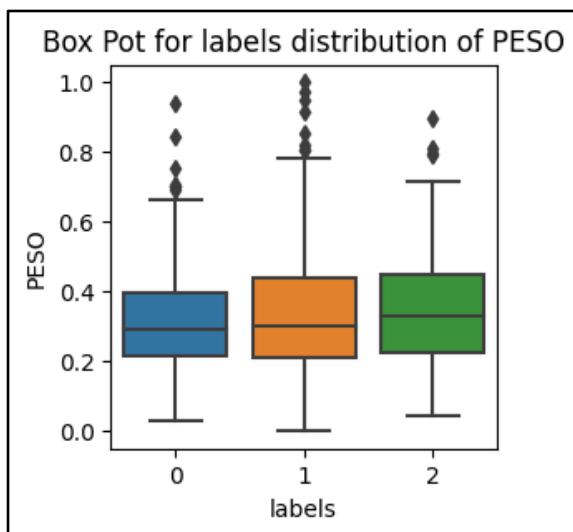
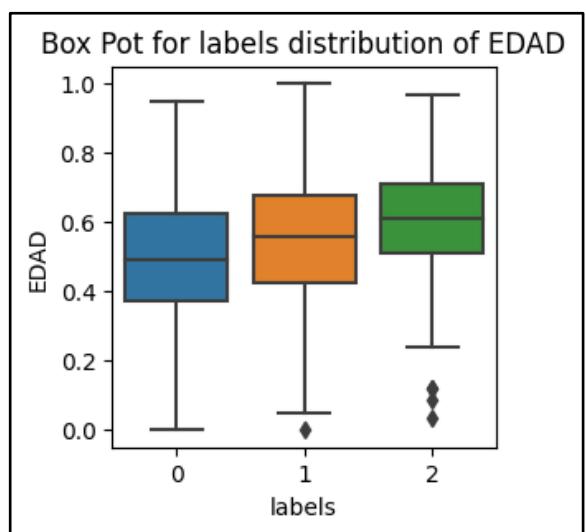
	EDAD	PESO	TALLA	IMC	SEXO_1	SEXO_2	LONGITUD
k2_c0	45.164179	113.037313	164.007463	41.936419	0.251244	0.748756	465.223881
k2_c1	48.339394	115.333333	167.129293	41.146977	0.486869	0.513131	564.585859
k2_c2	51.388601	118.378238	171.450777	40.163683	0.756477	0.243523	692.461140

- **c0 (402)**: Longitud intestinal baja (465.22 cm), en personas de menor edad, menor peso y talla, con IMC en torno a 41.93, y predominantemente mujeres.
- **c1 (495)**: Longitud intestinal media (564.58 cm), en personas de edad, peso y talla algo mayor que en el cluster 1, IMC en torno a 41.14, sin clara diferencia entre sexos.
- **c2 (193)**: Longitud intestinal alta (692.46 cm), en personas de más alta edad, peso y talla, IMC en torno a 40.16, y predominantemente en hombres.

RESULTADOS

Clustering

	EDAD	PESO	TALLA	IMC	SEXO_1	SEXO_2	LONGITUD
k3_c0	0.494308	0.314946	0.442451	0.314398	0.251244	0.748756	465.223881
k3_c1	0.548125	0.331002	0.502486	0.299122	0.486869	0.513131	564.585859
k3_c2	0.599807	0.352295	0.585592	0.280093	0.756477	0.243523	692.461140



RESULTADOS

Interpolación de datos

Machine learning sobremuestreo modo SMOTE (Synthetic Minority Over-sampling Technique)

c0 (495) / c1 (495) / c2 (495)

Modelización

Fase de selección de modelos



Gradient Boosting Classifier (clasificación XGBoost)

```
[ ] #https://pycaret.gitbook.io/docs/
from pycaret.classification import *

data_in=df_enriched[['EDAD', 'IMC', 'SEXO_1', 'SEXO_2', 'labels']].copy()

s=setup(data_in,target='labels', session_id=123) #, remove_outliers = True , feature_selection = True
```

```
▶ #find best model
best = compare_models()
print(best)
```

RESULTADOS

Modelización



Gradient Boosting Classifier (clasificación XGBoost)

	Description	Value
0	Session id	123
1	Target	labels
2	Target type	Multiclass
3	Original data shape	(1497, 5)
4	Transformed data shape	(1497, 5)
5	Transformed train set shape	(1047, 5)
6	Transformed test set shape	(450, 5)
7	Numeric features	4
8	Preprocess	True
9	Imputation type	simple
10	Numeric imputation	mean
11	Categorical imputation	mode
12	Fold Generator	StratifiedKFold
13	Fold Number	10
14	CPU Jobs	-1
15	Use GPU	False
16	Log Experiment	False
17	Experiment Name	clf-default-name
18	USI	e31f

Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC	TT (Sec)
gbc	Gradient Boosting Classifier	0.3473	0.7069	0.6470	0.5575	0.5098	0.4810	0.3248
lr	Logistic Regression	0.5367	0.7117	0.5367	0.5069	0.4905	0.3051	0.3235
lda	Linear Discriminant Analysis	0.5358	0.7120	0.5358	0.5028	0.4883	0.3037	0.3223
nb	Naive Bayes	0.5330	0.6736	0.5330	0.5095	0.4540	0.2994	0.3220
ada	Ada Boost Classifier	0.5330	0.6994	0.5330	0.5198	0.5164	0.2996	0.3055
ridge	Ridge Classifier	0.5310	0.0000	0.5310	0.5041	0.4526	0.2965	0.3297
et	Extra Trees Classifier	0.5282	0.7189	0.5282	0.5254	0.5249	0.2923	0.2935
lightgbm	Light Gradient Boosting Machine	0.5224	0.7027	0.5224	0.5220	0.5192	0.2838	0.2856
rf	Random Forest Classifier	0.5214	0.6975	0.5214	0.5183	0.5176	0.2821	0.2835
xgboost	Extreme Gradient Boosting	0.5177	0.6975	0.5177	0.5171	0.5145	0.2765	0.2781
dt	Decision Tree Classifier	0.5043	0.6296	0.5043	0.5027	0.5019	0.2565	0.2573
knn	K Neighbors Classifier	0.4748	0.6558	0.4748	0.4829	0.4759	0.2121	0.2134
qda	Quadratic Discriminant Analysis	0.4555	0.6793	0.4555	0.3885	0.3383	0.1840	0.2708
svm	SVM - Linear Kernel	0.4192	0.0000	0.4192	0.2783	0.3049	0.1296	0.1584
dummy	Dummy Classifier	0.3314	0.5000	0.3314	0.1098	0.1650	0.0000	0.0000

```
GradientBoostingClassifier(ccp_alpha=0.0, criterion='friedman_mse', init=None,
                           learning_rate=0.1, loss='log_loss', max_depth=3,
                           max_features=None, max_leaf_nodes=None,
                           min_impurity_decrease=0.0, min_samples_leaf=1,
                           min_samples_split=2, min_weight_fraction_leaf=0.0,
                           n_estimators=100, n_iter_no_change=None,
                           random_state=123, subsample=1.0, tol=0.0001,
                           validation_fraction=0.1, verbose=0,
                           warm_start=False)
```

RESULTADOS

Modelización

Modelo predictivo de clasificación con XGBoost

```
[ ] #X= df_result[['EDAD', 'IMC', 'SEXO_1', 'SEXO_2']].copy()
#y= df_result['labels'].copy()

X= df_enriched[transformed_columns].copy()
y= df_enriched['labels'].copy()

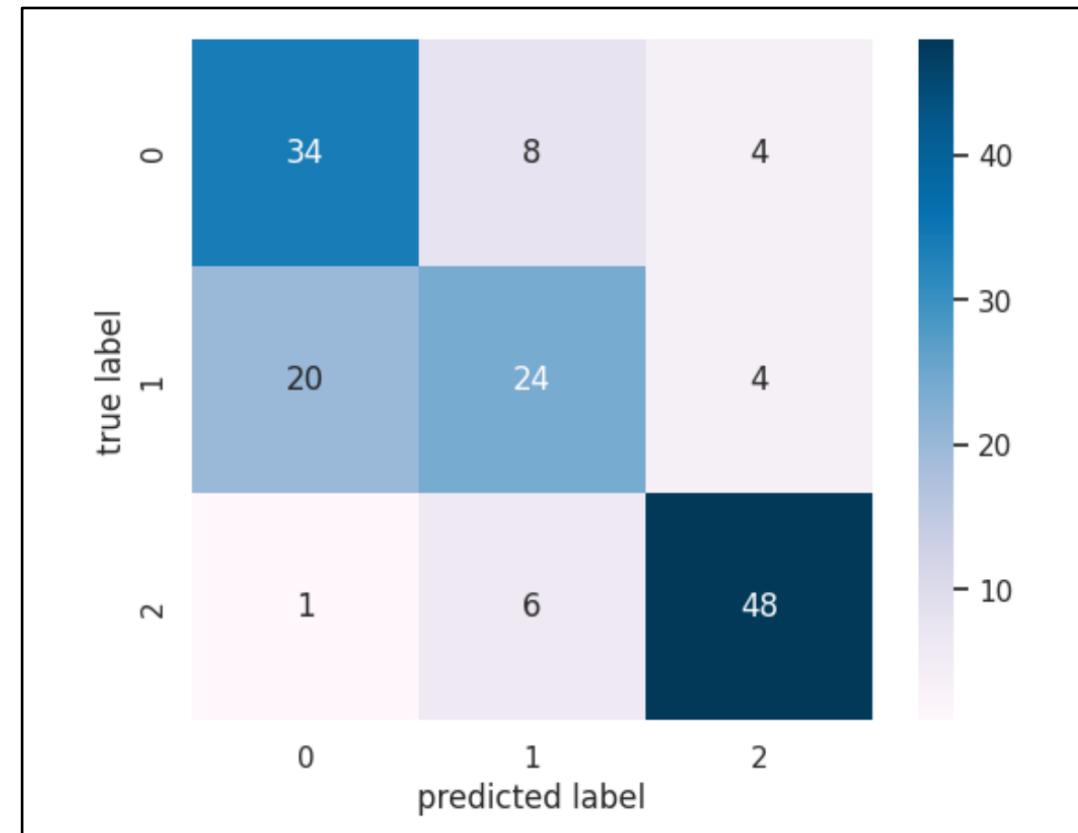
# Split dataset into training set and test set
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.1, random_state=23) # 80% training and 20% test

X_eval= X_test.copy()
y_eval= y_test.copy()
#y_pred= GradientBoostingClassifier(n_estimators=100, learning_rate = 0.01, max_features=5, max_depth = 10, random_state = 26).fit(X_train,y)
#n_estimators50-max_depth20-lr0.05mf1-66.0
#y_pred= GradientBoostingClassifier(n_estimators=50, learning_rate = 0.05, max_features=1, max_depth = 20, random_state = 26).fit(X_train,y)

#n_estimators150-max_depth6-lr0.5mf3-67.0
y_pred= GradientBoostingClassifier(n_estimators=150, learning_rate = 0.5, max_features=3, max_depth = 8, random_state = 26).fit(X_train,y_train)

#confussion matrix metrics
print(str(23))
print(metrics.classification_report(y_eval,y_pred))
#confusion matrix plot
sn.set()
mat = confusion_matrix(y_eval, y_pred)
sn.heatmap(mat, square=True, annot=True, fmt='d', cbar=True, cmap='PuBu')
plt.xlabel('predicted label')
plt.ylabel('true label');
```

	precision	recall	f1-score	support
0	0.62	0.74	0.67	46
1	0.63	0.50	0.56	48
2	0.86	0.87	0.86	55
accuracy			0.71	149
macro avg	0.70	0.70	0.70	149
weighted avg	0.71	0.71	0.71	149



RESULTADOS

Modelización

Modelo predictivo de clasificación con XGBoost (ajuste del modelo)

```
#n_estimators=100, learning_rate = 0.01, max_features=5, max_depth = 10
#n_estimators 25 max_depth 3 learning_rate 0.001 max_features 5 scores.mean 0.5696969696969696
n_estimators = [25,50,100,125,150,175,200]
max_depths = [2,3,5,7,8,9,10,15,20,25]
learning_rates = [0.001,0.01,0.05,0.1,0.2,0.5]
max_features=[1,3,5,10,15,20]
maxmean = 0
X_eval= X_test.copy()
y_eval= y_test.copy()

for n_estimator in n_estimators:
    for max_depth in max_depths:
        for lr in learning_rates:
            for mf in max_features:
                y_pred= GradientBoostingClassifier(n_estimators=n_estimator, learning_rate = lr, max_features=mf, max_depth = max_depth, random_state
                #confusion matrix metrics
                m=metrics.classification_report(y_eval,y_pred)

                if maxmean<100*float(m.split('\n')[2].split('      ')[4]):
                    maxmean=100*float(m.split('\n')[2].split('      ')[4])
                    print('nestimators'+str(n_estimator)+'-max_depth'+str(max_depth)+'-lr'+str(lr)+'mf'+str(mf)+'-'+str(maxmean)+'
print(m)
```

nestimators25-max_depth2-lr0.001mf1-57.99999999999999				
	precision	recall	f1-score	support
0	0.46	0.78	0.58	46
1	0.30	0.42	0.35	48
2	1.00	0.05	0.10	55
accuracy			0.40	149
macro avg	0.58	0.42	0.34	149
weighted avg	0.61	0.40	0.33	149

nestimators25-max_depth2-lr0.001mf3-60.0				
	precision	recall	f1-score	support
0	0.49	0.76	0.60	46
1	0.40	0.42	0.41	48
2	0.71	0.36	0.48	55
accuracy			0.50	149
macro avg	0.54	0.51	0.50	149
weighted avg	0.54	0.50	0.49	149

nestimators25-max_depth7-lr0.001mf10-61.0				
	precision	recall	f1-score	support
0	0.52	0.74	0.61	46
1	0.35	0.31	0.33	48
2	0.76	0.56	0.65	55
accuracy			0.54	149
macro avg	0.54	0.54	0.53	149
weighted avg	0.55	0.54	0.53	149

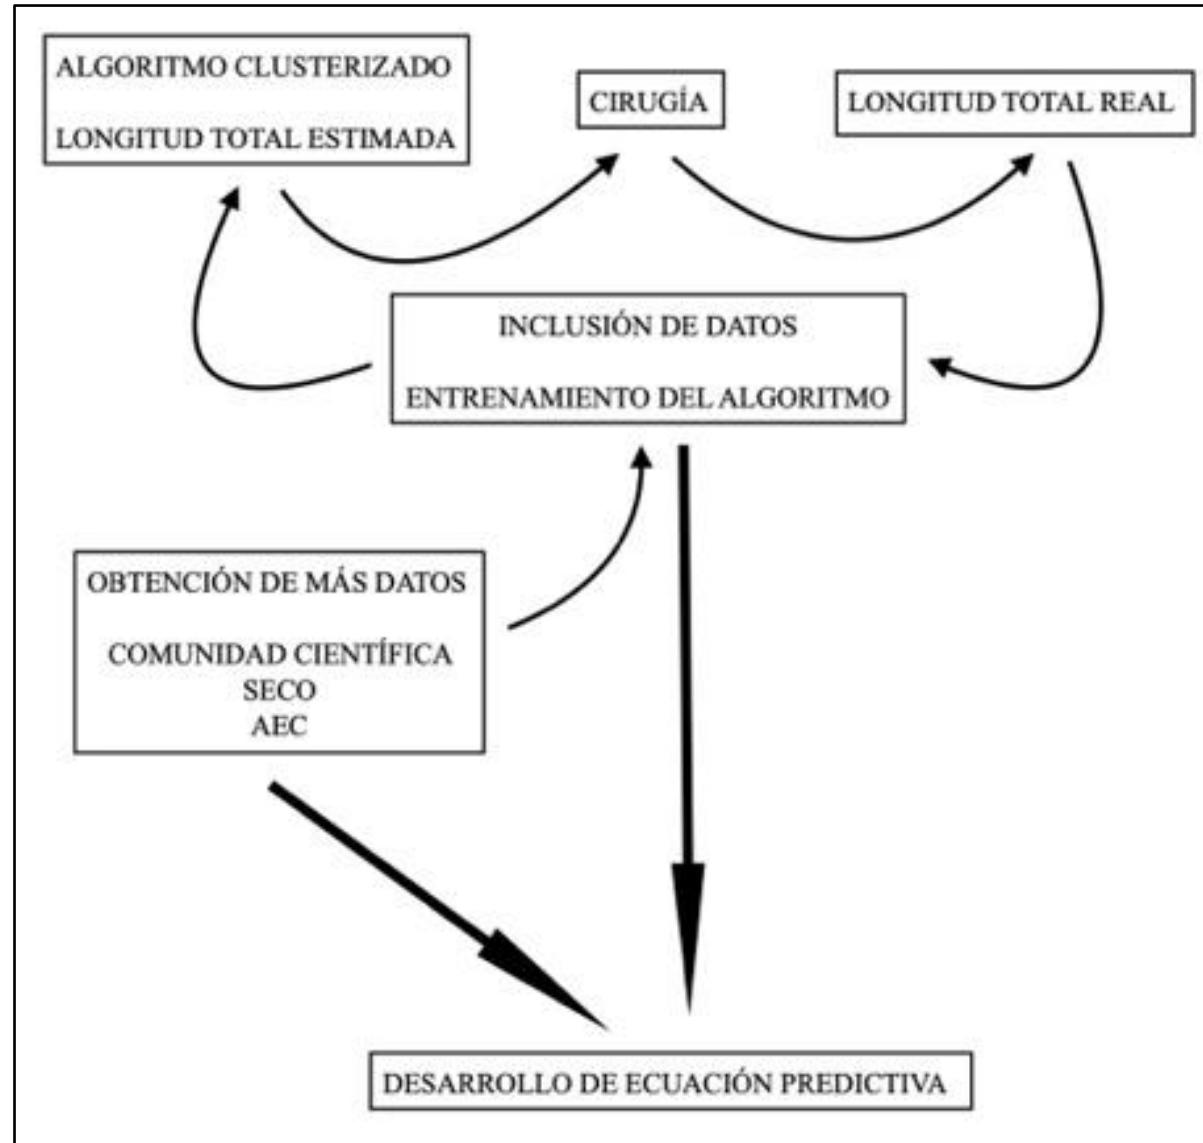
nestimators25-max_depth9-lr0.2mf1-63.0				
	precision	recall	f1-score	support
0	0.61	0.65	0.63	46
1	0.62	0.54	0.58	48
2	0.79	0.84	0.81	55
accuracy			0.68	149
macro avg	0.67	0.68	0.67	149
weighted avg	0.68	0.68	0.68	149

nestimators25-max_depth10-lr0.001mf1-65.0				
	precision	recall	f1-score	support
0	0.59	0.74	0.65	46
1	0.51	0.52	0.52	48
2	0.88	0.67	0.76	55
accuracy			0.64	149
macro avg	0.66	0.64	0.64	149
weighted avg	0.67	0.64	0.65	149

nestimators50-max_depth20-lr0.05mf1-66.0				
	precision	recall	f1-score	support
0	0.65	0.67	0.66	46
1	0.65	0.58	0.62	48
2	0.84	0.89	0.87	55
accuracy			0.72	149
macro avg	0.71	0.72	0.71	149
weighted avg	0.72	0.72	0.72	149

nestimators150-max_depth8-lr0.5mf3-67.0				
	precision	recall	f1-score	support
0	0.62	0.74	0.67	46
1	0.63	0.50	0.56	48
2	0.86	0.87	0.86	55
accuracy			0.71	149
macro avg	0.70	0.70	0.70	149

LÍNEAS FUTURAS



CONCLUSIONES

Primera: Conocer la longitud total del intestino delgado permite individualizar las técnicas quirúrgicas de cirugía bariátrica derivativa y optimizar los resultados en cuanto a disminución de complicaciones postoperatorias, pérdida ponderal y resolución de comorbilidades.

Segunda: Existe una diferencia notable en la longitud total del intestino delgado entre los dos sexos, siendo mayor en el sexo masculino. La relación entre la edad, el peso, la talla y el IMC con la longitud total del intestino delgado existe, pero es muy débil, siendo la talla la que muestra la correlación más alta.

Tercera: El desarrollo de una ecuación de predicción de la longitud total del intestino delgado a partir de un modelo de regresión considerando el sexo, la edad, el peso, la talla y el IMC con los datos disponibles en este estudio muestra un porcentaje de acierto muy bajo ya que el número de datos es insuficiente.

Cuarta: El desarrollo de un algoritmo predictivo a través del análisis de datos, basado en técnicas de clustering y machine learning, con un modelo predictivo de clasificación XGBoost, es factible y aplicable considerando el sexo, la edad, el peso, la talla y el IMC, creando un total de tres grupos que determinen de forma cualitativa una longitud total baja, una longitud total media, y una longitud total alta, donde puedan clasificarse todos los pacientes.

Quinta: Es necesario contar con más datos tanto en número de pacientes, como en variables a considerar, para enriquecer y entrenar el algoritmo de cara a mejorar los porcentajes de acierto del algoritmo y, en el futuro, desarrollar una fórmula predictiva directa de la longitud total del intestino delgado con precisión a nivel de cm.

TRABAJO FIN DE MÁSTER

CASO DE NEGOCIO

MODELO PREDICTIVO DE LA LONGITUD TOTAL DEL INTESTINO DELGADO PARA APLICAR EN CIRUGÍA BARIÁTRICA BASADO EN ANÁLISIS DE DATOS Y TÉCNICAS DE INTELIGENCIA ARTIFICIAL

Máster in Data Science & Artificial Intelligence (MIDS & AI) 2023

CESTE Escuela Internacional de Negocios

Alumno

JOSÉ FERNANDO TREBOLLE

Tutores

JESÚS LOBO POYO

CARMEN PELLICER LOSTAO

